

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

Институт кибербезопасности и цифровых технологий КБ-4 «Интеллектуальные системы информационной безопасности»

Отчет по практической и лабораторной работе

по дисциплине: «Анализ защищенности систем искусственного интеллекта»

Выполнила:

Студентка группы ББМО-02-22

Бардасова Ирина Александровна

Проверил:

К.т.н. Спирин Андрей Андреевич

Содержание

Ход работы	3
1 Создание атак на модель НС	3
2 Защита от атак	13
Заключение	19

Ход работы

Шаг 1. Выполним импорт необходимых библиотек (рисунок 1).

```
In [1]:
    import numpy as np
    import matplotlib.pyplot as plt
    import torch
    import torch.nn as nn
    import torch.nn.functional as F
    import torch.optim as optim
    from torchvision import transforms,datasets
```

Рисунок 1 – Импорт библиотек

Шаг 2. Загрузим набор данных (MNIST), разобьем данные на подвыборки (рисунок 2).

Рисунок 2 – Набор данных MNIST

Шаг 3. Настроим использование графического ускорителя (рисунок 3).

```
In [3]: use_cuda=True
  device = torch.device("cuda" if (use_cuda and torch.cuda.is_available()) else "cpu")
```

Рисунок 3 – Использование графического ускорителя

1 Создание атак на модель НС

Шаг 4. Создадим класс HC на основе фреймворка torch (рисунок 4).

```
In [4]: class Net(nn.Module):
          def init (self):
             super(Net, self).__init__()
             self.conv1 = nn.Conv2d(1, 32, 3, 1)
             self.conv2 = nn.Conv2d(32, 64, 3, 1)
             self.dropout1 = nn.Dropout2d(0.25)
             self.dropout2 = nn.Dropout2d(0.5)
             self.fc1 = nn.Linear(9216, 128)
             self.fc2 = nn.Linear(128, 10)
           def forward(self, x):
             x = self.conv1(x)
             x = F.relu(x)
             x = self.conv2(x)
             x = F.relu(x)
             x = F.max_pool2d(x, 2)
             x = self.dropout1(x)
             x = torch.flatten(x, 1)
             x = self.fc1(x)
             x = F.relu(x)
             x = self.dropout2(x)
             x = self.fc2(x)
             output = F.log_softmax(x, dim=1)
             return output
```

Рисунок 4 – Класс НС

Шаг 5. Проверим работоспособность созданного класса НС (рисунок 5).

```
In [5]: model = Net().to(device)
```

Рисунок 5 – Работоспособность созданного класса НС

Шаг 6. Создадим оптимизатор, функцию потерь и трейнер сети (рисунок 6).

```
In [6]:
    optimizer = optim.Adam(model.parameters(),lr=0.0001, betas=(0.9, 0.999))
    criterion = nn.NLLLoss()
    scheduler = optim.lr_scheduler.ReduceLROnPlateau(optimizer, mode='min', factor=0.1, patience=3)
```

Рисунок 6 – Созданный оптимизатор

Шаг 7. Определим функцию обучения сети (рис. 7).

```
In [7]: def fit(model,device,train_loader,val_loader,epochs):
           data_loader = { 'train':train_loader, 'val':val_loader}
           print("Fitting the model...")
           train_loss,val_loss=[],[]
           for epoch in range(epochs):
             loss_per_epoch,val_loss_per_epoch=0,0
             for phase in ('train','val'):
               for i,data in enumerate(data_loader[phase]):
                 input,label = data[0].to(device),data[1].to(device)
                 output = model(input)
                 #calculating loss on the output
                 loss = criterion(output,label)
                 if phase == 'train':
                   optimizer.zero_grad()
                   #grad calc w.r.t Loss func
                   loss.backward()
                   #update weights
                   optimizer.step()
                   loss per epoch+=loss.item()
                 else:
                   val_loss_per_epoch+=loss.item()
             scheduler.step(val_loss_per_epoch/len(val_loader))
             print("Epoch: {} Loss: {} Val_Loss: {}".format(epoch+1,loss_per_epoch/len(train_loader),val_loss_per_epoch/len(val_loader)
             train_loss.append(loss_per_epoch/len(train_loader))
             val_loss.append(val_loss_per_epoch/len(val_loader))
           return train_loss,val_loss
```

Рисунок 7 – Определяем функцию обучения сети

Шаг 8. Обучим модель (рисунок 8).

```
In [8]:
         loss, val loss = fit(model, device, train loader, val loader, 10)
      Fitting the model...
      /usr/local/lib/python3.10/dist-packages/torch/nn/functional.py:1345: UserWarning: 0
      d, which is deprecated and will result in an error in a future release. To retain t
      e use dropout instead. Note that dropout2d exists to provide channel-wise dropout of
      el dimension, and an optional batch dimension (i.e. 3D or 4D inputs).
        warnings.warn(warn msg)
      Epoch: 1 Loss: 0.29064843464819934 Val Loss: 0.13973914129167625
      Epoch: 2 Loss: 0.11209722856724741 Val Loss: 0.09410980466786437
      Epoch: 3 Loss: 0.08527212373731685 Val Loss: 0.09013760282852333
      Epoch: 4 Loss: 0.07664654940550142 Val Loss: 0.083568693905282
      Epoch: 5 Loss: 0.06749064147849225 Val Loss: 0.08116593277261915
      Epoch: 6 Loss: 0.06208608291131742 Val_Loss: 0.09247260077951423
      Epoch: 7 Loss: 0.06100456084646738 Val_Loss: 0.08571256819688092
      Epoch: 8 Loss: 0.05803848488737129 Val_Loss: 0.07620353192351904
      Epoch: 9 Loss: 0.05555220137219747 Val_Loss: 0.07989234270428483
      Epoch: 10 Loss: 0.054739571796726935 Val Loss: 0.08621458863847627
```

Рисунок 8 – Обучение модели

Шаг 9. Построим графики потерь при обучении и валидации в зависимости от эпохи (рисунок 9).

```
In [9]:
         fig = plt.figure(figsize=(5,5))
         plt.plot(np.arange(1,11), loss, "*-",label="Loss")
         plt.plot(np.arange(1,11), val_loss,"o-",label="Val Loss")
         plt.xlabel("Num of epochs")
         plt.legend()
         plt.show()
       0.30
                                                          Loss
                                                          Val Loss
      0.30
                                                       Loss
                                                       Val Loss
      0.25
      0.20
      0.15
      0.10
      0.05
                   2
                                        6
                                                   8
                                                             10
                               Num of epochs
```

Рисунок 9 – Графики потерь при обучении и валидации

Шаг 10. Создадим функции атак FGSM, I-FGSM, MI-FGSM (рисунок 10-11).

```
In [10]:
          def fgsm attack(input,epsilon,data grad):
            pert_out = input + epsilon*data_grad.sign()
            pert_out = torch.clamp(pert_out, 0, 1)
            return pert_out
In [11]:
          def ifgsm_attack(input,epsilon,data_grad):
            iter = 10
            alpha = epsilon/iter
            pert_out = input
            for i in range(iter-1):
              pert_out = pert_out + alpha*data_grad.sign()
              pert_out = torch.clamp(pert_out, 0, 1)
              if torch.norm((pert_out-input),p=float('inf')) > epsilon:
                break
            return pert_out
```

Рисунок 10 – Функции атак FGSM, I-FGSM

Рисунок 11 – Функция атаки MI-FGSM

Шаг 11. Создадим функцию проверки (рисунок 12).

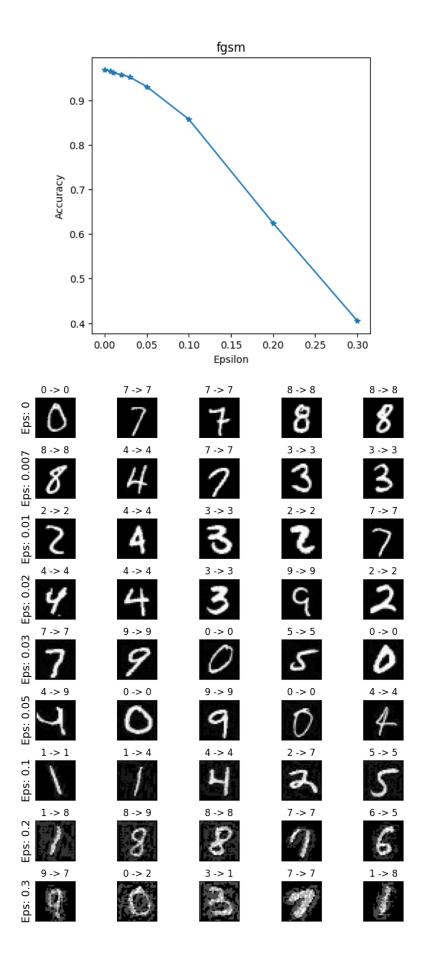
```
In [13]:
          def test(model,device,test_loader,epsilon,attack):
            correct = 0
             adv_examples = []
             for data, target in test_loader:
               data, target = data.to(device), target.to(device)
              data.requires grad = True
              output = model(data)
              init pred = output.max(1, keepdim=True)[1]
              if init pred.item() != target.item():
                 continue
              loss = F.nll_loss(output, target)
              model.zero_grad()
              loss.backward()
              data_grad = data.grad.data
              if attack == "fgsm":
                 perturbed data = fgsm attack(data,epsilon,data grad)
              elif attack == "ifgsm":
                 perturbed_data = ifgsm_attack(data,epsilon,data_grad)
               elif attack == "mifgsm":
                 perturbed_data = mifgsm_attack(data,epsilon,data_grad)
              output = model(perturbed_data)
              final pred = output.max(1, keepdim=True)[1]
               if final pred.item() == target.item():
                 correct += 1
               if (epsilon == 0) and (len(adv_examples) < 5):
                 adv ex = perturbed data.squeeze().detach().cpu().numpy()
                 adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
  else:
    if len(adv_examples) < 5:
      adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
      adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
final_acc = correct/float(len(test_loader))
print("Epsilon: {}\Test Accuracy = {} / {} = {}".format(epsilon, correct, len(test_loader), final_acc))
 return final_acc, adv_examples
```

Рисунок 12 – Создали функцию проверки

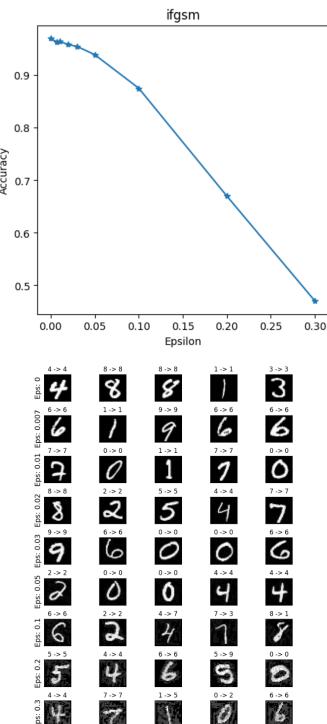
Шаг 12. Построим графики успешности атак(Ассигасу/эпсилон) и примеры выполненных атак в зависимости от степени возмущения epsilon (рисунки 13).

```
In [14]:
          epsilons = [0,0.007,0.01,0.02,0.03,0.05,0.1,0.2,0.3]
          for attack in ("fgsm", "ifgsm", "mifgsm"):
            accuracies = []
            examples = []
            for eps in epsilons:
             acc, ex = test(model, device,test_loader,eps,attack)
              accuracies.append(acc)
              examples.append(ex)
            plt.figure(figsize=(5,5))
            plt.plot(epsilons, accuracies, "*-")
            plt.title(attack)
            plt.xlabel("Epsilon")
            plt.ylabel("Accuracy")
            plt.show()
            cnt = 0
            plt.figure(figsize=(8,10))
            for i in range(len(epsilons)):
              for j in range(len(examples[i])):
                cnt += 1
                plt.subplot(len(epsilons),len(examples[0]),cnt)
                plt.xticks([], [])
                plt.yticks([], [])
                if j == 0:
                  plt.ylabel("Eps: {}".format(epsilons[i]), fontsize=14)
                orig,adv,ex = examples[i][j]
plt.title("{} -> {}".format(orig, adv))
                plt.imshow(ex, cmap="gray")
            plt.tight layout()
            plt.show()
```

```
Epsilon: 0
              Test Accuracy = 9681 / 10000 = 0.9681
Epsilon: 0.007 Test Accuracy = 9658 / 10000 = 0.9658
Epsilon: 0.01 Test Accuracy = 9619 / 10000 = 0.9619
Epsilon: 0.02 Test Accuracy = 9569 / 10000 = 0.9569
Epsilon: 0.03 Test Accuracy = 9517 / 10000 = 0.9517
Epsilon: 0.05 Test Accuracy = 9304 / 10000 = 0.9304
              Test Accuracy = 8572 / 10000 = 0.8572
Epsilon: 0.1
Epsilon: 0.2
              Test Accuracy = 6245 / 10000 = 0.6245
Epsilon: 0.3
               Test Accuracy = 4053 / 10000 = 0.4053
```



ш = Epsilon: 0 Test Accuracy = 9702 / 10000 = 0.9702 Epsilon: 0.007 Test Accuracy = 9636 / 10000 = 0.9636 Test Accuracy = 9644 / 10000 = 0.9644 Epsilon: 0.01 Test Accuracy = 9585 / 10000 = 0.9585 Epsilon: 0.02 Test Accuracy = 9549 / 10000 = 0.9549 Epsilon: 0.03 Test Accuracy = 9393 / 10000 = 0.9393 Epsilon: 0.05 Test Accuracy = 8754 / 10000 = 0.8754Epsilon: 0.1 Epsilon: 0.2 Test Accuracy = 6701 / 10000 = 0.6701Test Accuracy = 4703 / 10000 = 0.4703 Epsilon: 0.3 ifacm ifgsm



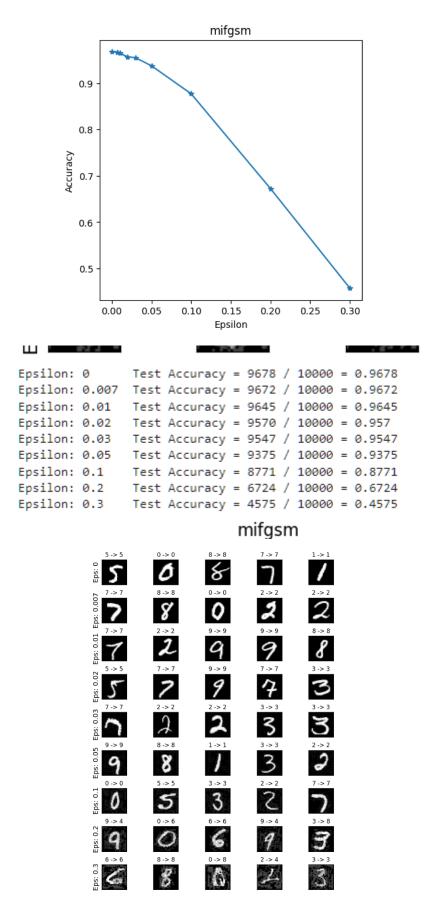


Рисунок 13 – Графики успешности атак(Ассигасу/эпсилон) и примеры выполненных атак

2 Защита от атак

Шаг 13. Создадим 2 класса НС (рисунок 14).

In [15]:

```
class NetF(nn.Module):
           def init (self):
              super(NetF, self).__init__()
              self.conv1 = nn.Conv2d(1, 32, 3, 1)
              self.conv2 = nn.Conv2d(32, 64, 3, 1)
              self.dropout1 = nn.Dropout2d(0.25)
              self.dropout2 = nn.Dropout2d(0.5)
              self.fc1 = nn.Linear(9216, 128)
              self.fc2 = nn.Linear(128, 10)
            def forward(self, x):
              x = self.conv1(x)
              x = F.relu(x)
              x = self.conv2(x)
              x = F.relu(x)
              x = F.max_pool2d(x, 2)
              x = self.dropout1(x)
              x = torch.flatten(x, 1)
              x = self.fc1(x)
              x = F.relu(x)
              x = self.dropout2(x)
              x = self.fc2(x)
              return x
In [16]:
         class NetF1(nn.Module):
           def __init__(self):
             super(NetF1, self).__init__()
              self.conv1 = nn.Conv2d(1, 16, 3, 1)
              self.conv2 = nn.Conv2d(16, 32, 3, 1)
             self.dropout1 = nn.Dropout2d(0.25)
             self.dropout2 = nn.Dropout2d(0.5)
              self.fc1 = nn.Linear(4608, 64)
              self.fc2 = nn.Linear(64, 10)
            def forward(self, x):
             x = self.conv1(x)
             x = F.relu(x)
             x = self.conv2(x)
             x = F.relu(x)
             x = F.max_pool2d(x, 2)
             x = self.dropout1(x)
             x = torch.flatten(x, 1)
             x = self.fc1(x)
             x = F.relu(x)
             x = self.dropout2(x)
              x = self.fc2(x)
              return x
```

Рисунок 14 – 2 класса НС

Шаг 14. Переопределим функцию обучения и тестирования (рисунок 15).

```
def fit(model,device,optimizer,scheduler,criterion,train_loader,val_loader,Temp,epochs):
  data_loader = {'train':train_loader,'val':val_loader}
  print("Fitting the model...")
  train loss, val loss=[],[]
  for epoch in range(epochs):
    loss\_per\_epoch, val\_loss\_per\_epoch=0, 0
    for phase in ('train','val'):
      for i,data in enumerate(data_loader[phase]):
       input,label = data[0].to(device),data[1].to(device)
       output = model(input)
       output = F.log_softmax(output/Temp,dim=1)
        #calculating loss on the output
        loss = criterion(output,label)
       if phase == 'train':
         optimizer.zero_grad()
         #grad calc w.r.t Loss func
         loss.backward()
         #update weights
         optimizer.step()
         loss_per_epoch+=loss.item()
      else:
       val_loss_per_epoch+=loss.item()
    scheduler.step(val_loss_per_epoch/len(val_loader))
    print("Epoch: {} Loss: {} Val_Loss: {}".format(epoch+1,loss_per_epoch/len(train_loader),val_loss_per_epoch/len(val_loader)
    train_loss.append(loss_per_epoch/len(train_loader))
    val_loss.append(val_loss_per_epoch/len(val_loader))
  return train_loss,val_loss
  print("Epoch: {} Loss: {} Val_Loss: {}".format(epoch+1,loss_per_epoch/len(train_loader),val_los
  train_loss.append(loss_per_epoch/len(train_loader))
  val_loss.append(val_loss_per_epoch/len(val_loader))
return train_loss,val_loss
def test(model,device,test_loader,epsilon,Temp,attack):
  correct=0
  adv_examples = []
  for data, target in test_loader:
    data, target = data.to(device), target.to(device)
    data.requires_grad = True
    output = model(data)
    output = F.log_softmax(output/Temp,dim=1)
    init_pred = output.max(1, keepdim=True)[1]
    if init_pred.item() != target.item():
      continue
    loss = F.nll_loss(output, target)
    model.zero_grad()
    loss.backward()
    data_grad = data.grad.data
    if attack == "fgsm":
      perturbed_data = fgsm_attack(data,epsilon,data_grad)
    elif attack == "ifgsm":
      perturbed_data = ifgsm_attack(data,epsilon,data_grad)
    elif attack == "mifgsm":
      perturbed_data = mifgsm_attack(data,epsilon,data_grad)
    output = model(perturbed_data)
    final_pred = output.max(1, keepdim=True)[1]
    if final_pred.item() == target.item():
       correct += 1
       if (epsilon == 0) and (len(adv examples) < 5):
```

```
percurbed_data = ligsm_actack(data,epsiton,data_grad)
   elif attack == "mifgsm":
    perturbed_data = mifgsm_attack(data,epsilon,data_grad)
   output = model(perturbed_data)
   final_pred = output.max(1, keepdim=True)[1]
   if final_pred.item() == target.item():
     correct += 1
     if (epsilon == 0) and (len(adv_examples) < 5):
       adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
       adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
       if len(adv_examples) < 5:
          adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
         adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
final_acc = correct/float(len(test_loader))
print("Epsilon: {}\tTest Accuracy = {} / {} = {}".format(epsilon, correct, len(test_loader), final_acc))
return final_acc,adv_examples
```

Рисунок 15 – Переопределили функцию обучения и тестирования

Шаг 15. Создадим функцию защиты методом дистилляции (рисунок 16).

```
In [18]: def defense(device,train_loader,val_loader,test_loader,epochs,Temp,epsilons):
             modelF = NetF().to(device)
             optimizerF = optim.Adam(modelF.parameters(),lr=0.0001, betas=(0.9, 0.999))
             schedulerF = optim.lr_scheduler.ReduceLROnPlateau(optimizerF, mode='min', factor=0.1, patience=3)
             modelF1 = NetF1().to(device)
             optimizerF1 = optim.Adam(modelF1.parameters(),lr=0.0001, betas=(0.9, 0.999))
             schedulerF1 = optim.lr_scheduler.ReduceLROnPlateau(optimizerF1, mode='min', factor=0.1, patience=3)
             loss \texttt{F}, val\_loss \texttt{F} = \texttt{fit}(\texttt{modelF}, \texttt{device}, \texttt{optimizerF}, \texttt{schedulerF}, \texttt{criterion}, \texttt{train\_loader}, \texttt{val\_loader}, \texttt{Temp}, \texttt{epochs})
             fig = plt.figure(figsize=(5,5))
             plt.plot(np.arange(1,epochs+1), lossF, "*-",label="Loss")
             \verb|plt.plot(np.arange(1,epochs+1), val_lossF,"o-",label="Val Loss")|\\
             plt.title("Network F")
             plt.xlabel("Num of epochs")
             plt.legend()
             plt.show()
             #converting target labels to soft labels
             for data in train_loader:
              input, label = data[0].to(device),data[1].to(device)
               softlabel = F.log_softmax(modelF(input),dim=1)
              data[1] = softlabel
             lossF1,val_lossF1=fit(modelF1,device,optimizerF1,schedulerF1,criterion,train_loader,val_loader,Temp,epochs)
             fig = plt.figure(figsize=(5,5))
             \verb|plt.plot(np.arange(1,epochs+1), lossF1, "*-",label="Loss")|\\
             plt.plot(np.arange(1,epochs+1), val_lossF1,"o-",label="Val Loss")
            plt.title("Network F'")
           fig = plt.figure(figsize=(5,5))
           plt.plot(np.arange(1,epochs+1), lossF1, "*-",label="Loss")
           plt.plot(np.arange(1,epochs+1), val_lossF1,"o-",label="Val Loss")
           plt.title("Network F'")
           plt.xlabel("Num of epochs")
           plt.legend()
           plt.show()
           model = NetF1().to(device)
           model.load_state_dict(modelF1.state_dict())
           for attack in ("fgsm", "ifgsm", "mifgsm"):
             accuracies = []
              examples = []
             for eps in epsilons:
               acc, ex = test(model,device,test_loader,eps,"fgsm")
               accuracies.append(acc)
                examples.append(ex)
           plt.figure(figsize=(5,5))
           plt.plot(epsilons, accuracies, "*-")
           plt.title(attack)
           plt.xlabel("Epsilon")
           plt.ylabel("Accuracy")
           plt.show()
           cnt = 0
           plt.figure(figsize=(8,10))
           for i in range(len(epsilons)):
             for j in range(len(examples[i])):
               plt.subplot(len(epsilons),len(examples[0]),cnt)
               plt.xticks([], [])
```

```
plt.ylabel("Accuracy")
plt.show()
cnt = 0
plt.figure(figsize=(8,10))
for i in range(len(epsilons)):
  for j in range(len(examples[i])):
    cnt += 1
    plt.subplot(len(epsilons),len(examples[0]),cnt)
    plt.xticks([], [])
    plt.yticks([], [])
    if j == 0:
      plt.ylabel("Eps: {}".format(epsilons[i]), fontsize=14)
    orig,adv,ex = examples[i][j]
    plt.title("{} -> {}".format(orig, adv))
    plt.imshow(ex, cmap="gray")
plt.tight_layout()
plt.show()
```

Рисунок 16 – Создали функцию защиты методом дистилляции

Шаг 16. Получим результаты оценки защищенных сетей (рис. 17).

```
In [19]:
          Temp=100
          epochs=10
          epsilons=[0,0.007,0.01,0.02,0.03,0.05,0.1,0.2,0.3]
          defense(device, train_loader, val_loader, test_loader, epochs, Temp, epsilon:
        Fitting the model...
        Epoch: 1 Loss: 0.5875381317337817 Val_Loss: 0.0002477751061320305
        Epoch: 2 Loss: 0.37223328317865906 Val Loss: 5.8449041792118806e-05
        Epoch: 3 Loss: 0.300203464906997 Val_Loss: 1.1476876195047225e-06
        Epoch: 4 Loss: 0.22447578425227732 Val_Loss: 1.024925165111199e-05
        Epoch: 5 Loss: 0.1692605609525646 Val_Loss: 1.2469353526830674e-05
        Epoch: 6 Loss: 0.13844957534614116 Val_Loss: 1.5843172644963488e-06
        Epoch: 7 Loss: 0.12097579994431013 Val_Loss: 2.2935150191187858e-07
        Epoch: 8 Loss: 0.10792648130793007 Val_Loss: 2.1327660974475295e-05
        Epoch: 9 Loss: 0.09584144328942137 Val_Loss: 1.7687051848042756e-06
        Epoch: 10 Loss: 0.09228720086034559 Val_Loss: 6.794159198761917e-08
                                     Network F
               0.6
                                                        Loss

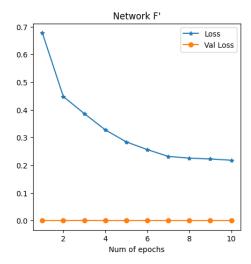
    Val Loss

               0.5
               0.4
               0.3
               0.2
               0.1
               0.0
                                                              10
```

Num of epochs

Fitting the model...

```
Epoch: 1 Loss: 0.677646332978676 Val_Loss: 1.142687419487629e-05
Epoch: 2 Loss: 0.44778661603998104 Val_Loss: 9.403289790498092e-07
Epoch: 3 Loss: 0.38619531052488193 Val_Loss: 0.00031147556453943253
Epoch: 4 Loss: 0.32751098905518494 Val_Loss: 1.0528198938118294e-06
Epoch: 5 Loss: 0.28392189496603476 Val_Loss: 3.608909228205448e-06
Epoch: 6 Loss: 0.2561870969625666 Val_Loss: 6.666882634149261e-05
Epoch: 7 Loss: 0.23164340963596394 Val_Loss: 6.86303600662086e-06
Epoch: 8 Loss: 0.2254040606729585 Val_Loss: 1.1486735893413424e-07
Epoch: 9 Loss: 0.22232407375608804 Val_Loss: 1.8782613551593385e-07
Epoch: 10 Loss: 0.21788871602455848 Val Loss: 2.5395520031224804e-06
```



Num or epochs

```
Epsilon: 0
               Test Accuracy = 9021 / 10000 = 0.9021
Epsilon: 0.007 Test Accuracy = 9050 / 10000 = 0.905
Epsilon: 0.01
               Test Accuracy = 9026 / 10000 = 0.9026
               Test Accuracy = 8919 / 10000 = 0.8919
Epsilon: 0.02
Epsilon: 0.03
               Test Accuracy = 8821 / 10000 = 0.8821
Epsilon: 0.05
               Test Accuracy = 8640 / 10000 = 0.864
Epsilon: 0.1
               Test Accuracy = 7763 / 10000 = 0.7763
Epsilon: 0.2
               Test Accuracy = 4493 / 10000 = 0.4493
               Test Accuracy = 1339 / 10000 = 0.1339
Epsilon: 0.3
               Test Accuracy = 9043 / 10000 = 0.9043
Epsilon: 0
Epsilon: 0.007 Test Accuracy = 9022 / 10000 = 0.9022
Epsilon: 0.01
               Test Accuracy = 9028 / 10000 = 0.9028
Epsilon: 0.02
               Test Accuracy = 8896 / 10000 = 0.8896
Epsilon: 0.03
               Test Accuracy = 8839 / 10000 = 0.8839
Epsilon: 0.05
               Test Accuracy = 8654 / 10000 = 0.8654
               Test Accuracy = 7774 / 10000 = 0.7774
Epsilon: 0.1
               Test Accuracy = 4543 / 10000 = 0.4543
Epsilon: 0.2
Epsilon: 0.3
               Test Accuracy = 1365 / 10000 = 0.1365
               Test Accuracy = 9018 / 10000 = 0.9018
Epsilon: 0
Epsilon: 0.007 Test Accuracy = 9007 / 10000 = 0.9007
Epsilon: 0.01
               Test Accuracy = 9022 / 10000 = 0.9022
               Test Accuracy = 8917 / 10000 = 0.8917
Epsilon: 0.02
               Test Accuracy = 8815 / 10000 = 0.8815
Epsilon: 0.03
Epsilon: 0.05
               Test Accuracy = 8602 / 10000 = 0.8602
Epsilon: 0.1
               Test Accuracy = 7735 / 10000 = 0.7735
               Test Accuracy = 4547 / 10000 = 0.4547
Epsilon: 0.2
               Test Accuracy = 1341 / 10000 = 0.1341
Epsilon: 0.3
```

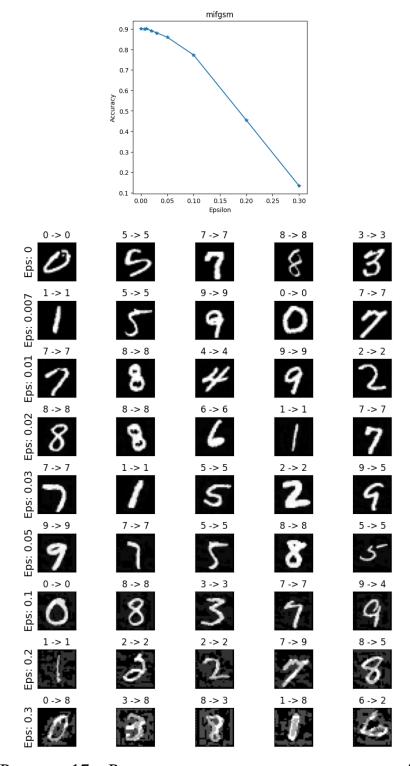


Рисунок 17 – Результаты оценки защищенных сетей

Заключение

В ходе выполнения данной работы по изучению защиты от атак на модели НС методом защитной дистилляции были выполнены следующие задачи:

- Задать нормалирующие преобразования для набора данных MNIST;
- Подготовить и обучить HC на базе фреймворка torch;
- Создать функции атак FGSM, I-FGSM, MI-FGSM и оценить их успешность;
- Создать два класса HC и переопределить функции обучения и тестирования;
 - Создать функцию защиты методом дистилляции;
 - Оценить результаты работы защищенных сетей.

Основная идея защитной дистиляции заключается в обучении устойчивой модели, путем передачи знаний от базовой модели, подверженной атакам, к новой модели, которая спроектирована для устойчивости к различным атакам.

Дистилляция дает более плоские локальные минимумы. Следовательно, небольшие изменения во входных данных с меньшей вероятностью изменят прогнозируемые значения.